AI 預測的背後是什麼？｜監督式學習、梯度下降、Overfitting 一次搞懂『機器學習系列第 0 集』

—— 機器學習系列・第 0 集　學習手冊 ——

項目	內容
影片標題	AI 預測的背後是什麼？｜監督式學習、梯度下降、Overfitting 一次搞懂『機器學習系列第 0 集』
作者／頻道	Enzo 獨自升級（https://www.youtube.com/@enzochangtw）
首播日期	2026-10-09（首次上載）
片長	約 14 分 17 秒（857 秒）
出處	YouTube 影片：https://www.youtube.com/watch?v=LVlJ1j_hTlY

編者按｜Source Note　本學習手冊以該影片的官方說明欄（Description）為主要內容依據；因所在網絡環境無法直接取得 YouTube 的逐字稿（closed captions），凡說明欄未明示而屬於補強背景知識的內容，均以「補充說明」或引用形式標示，並以可靠公開教材交叉核對（見末段「資料來源」）。因此本手冊並非逐字稿轉錄，而是配合影片結構整理的學習指引。

序　本手冊導讀｜How to use this handout

- 影片只有 14 分鐘，但說明欄把全片 18 個重點都列了出來。本手冊按「基礎 → 模型 → 訓練 → 風險」的順序重新組織。
- 每一章對應說明欄的 1 個或多個重點，並以「影片原述」和「補充說明」區隔來源。
- 章末設有「速記」與「自我檢核」要點，適合在看完影片後複習，或在進入第 1 集前預習。

1.　為什麼 AI 預測「無處不在」？從一天說起

影片一開頭拋出一個問題：「你今天從起床到現在，已經被機器學習服務了幾百次。」這不是誇飾，而是點出現代生活已離不開 AI 預測。理解 AI 預測背後的原理，能讓我們在「被預測」時，對結果的可信度與風險有更清醒的判斷。

以下場景（補充說明）只是其中一小部分：

日常場景	背後的機器學習任務（補充說明）
解鎖手機	臉部／指紋辨識屬於監督式學習中的分類問題。
早上的新聞推薦	以你的點擊、停留時間為訓練資料，預測你可能想看的下一則。
上班導航	依即時車流與歷史資料預測路徑時間。
信箱過濾垃圾信	把信件分成「正常」與「垃圾」兩類，是典型二元分類。
拍照的人像模式	用模型把人像與背景分離，模擬淺景深效果。
翻譯、輸入法、搜尋	語言模型、序列預測、排序學習等不同任務的組合。

重點｜Key takeaway　影片核心觀念：所有機器學習「都是在找一個函數」——把手機照片、對話、軌跡等輸入，對映到「人臉位置」「下一個字」「幾分鐘後到達」等輸出。

2.　傳統寫程式 vs 機器學習：方向完全相反

影片提出「方向完全相反」的對照，這是入門機器學習時最重要的觀念翻轉之一。

傳統寫程式	機器學習
人類寫下規則：if...then...	人類提供大量資料與答案
電腦按規則執行	電腦自己找出規則
把「解法」寫進程式	把「資料」交給電腦學會解法
若情境改變要改程式	若資料更新，模型可重新訓練

一個具體例子（補充說明）：

- **垃圾信偵測：**傳統方式：寫「若字包含『$』且金額 > 10000，標記為可疑」——規則多到很難維護。
- **機器學習：**機器學習方式：給模型 10 萬封已標記的郵件，讓它自己學會區分模式（用詞、寄件人、信頭結構等）。

> **影片原述｜Quote**　「最重要的一句話：所有機器學習都是在找一個函數。」

3. 模型、參數、學習：影片的「混音器」類比

影片用「混音器」作類比，是希望入門者直觀抓住三個抽象概念：

- **模型（Model）= 混音器**把模型看成一台「混音器」，把多條訊號源（特徵）按比例混成最終輸出。
- **參數（Parameter）= 旋鈕**混音器上的每顆旋鈕就是參數。旋鈕的位置決定混音器對每條訊號源加多少權重。
- **學習（Learning）= 調旋鈕**所謂「學習」，就是不斷依據資料調整這些旋鈕，直到輸出接近我們想要的結果。

以「預測房屋成交價」為例（補充說明）：

把坪數、房齡、距捷運站距離、學區等當作輸入，混音器則是一條線性公式：

預測價格 ≈ w_1 • 坪數 + w_2 • 房齡 + w_3 • 距離 + w_4 • 學區 + b

其中 w_1、w_2、w_3、w_4、b 就是參數（旋鈕），
「訓練」就是不斷微調這些 w 與 b，直到預測價格和實際成交價夠接近。

而神經網路、決策樹、支持向量機等不同「機器學習演算法」，差別就在於混音器的內部結構：

- **線性模型**線性回歸／邏輯回歸：只有一排旋鈕，線性組合。
- **樹模型**決策樹：依特徵逐層分流，像在資料中畫出一棵 if–else 樹。
- **深度神經網路**神經網路：很多層混音器疊在一起，能表示極複雜的非線性關係。

4. 機器學習三大門派

影片把機器學習主要任務分成三大門派。這是經典教科書（如 Hastie, Tibshirani, Friedman《The Elements of Statistical Learning》）常用的分類。

4.1 門派一：監督式學習（Supervised Learning）

每一筆訓練資料都附有「標準答案」。模型學習從輸入對映到答案的規律，再用於預測沒看過的新資料。

任務類型	輸出是？	典型案例
分類（Classification）	離散類別	垃圾信偵測、影像辨識、疾病診斷、情緒分析
回歸（Regression）	連續數值	房價預測、氣溫預測、銷售量預估、股價走勢

4.2 門派二：非監督式學習（Unsupervised Learning）

沒有標準答案。模型要在「無標記」的資料中自己找出結構或規則。

- **聚類（Clustering）**：依相似度把資料分成多群，常用於客群分群、文件分群。
- **降維（Dimensionality Reduction）**：把高維資料壓縮到 2D／3D 以便視覺化，例如 t-SNE、UMAP。
- **關聯規則（Association Rules）**：從交易資料中挖掘「買尿布的人常買啤酒」這類規律。

4.3 門派三：強化學習（Reinforcement Learning, RL）

代理人（agent）在環境中採取動作，根據回饋（獎勵／懲罰）學會一套策略。影片用「零食訓練狗」作類比，這正是 RL 的核心精神——做了才知道對不對。

- **代理人（Agent）**：學會下棋的 AlphaGo、無人車的駕駛策略。
- **環境（Environment）**：棋盤、道路、遊戲畫面。

- **動作（Action）**：落子、加速、轉向。
- **獎勵（Reward）**：贏棋 +1、撞到東西 −100、行車舒適度分數。

與監督式學習的差異（補充說明）：RL 沒有「正確答案」，只有「長期回報」；很多時候要把未來的獎勵折現回當下。

> **速記｜Mnemonic**　監督式：有題庫也有答案；非監督式：只有題庫，要自己想答案；強化學習：做完才知道老師怎麼打分數。

5. Loss 函數：模型到底有多「爛」？

影片問：「怎麼衡量模型有多爛？」答案是 Loss 函數（損失函數）：把「模型的預測」與「真實答案」之間的差距量化為一個數字。

Loss 越低，代表預測越接近真實；訓練的目標就是不斷把 Loss 降低。

5.1 均方誤差（MSE）：為什麼要「平方」？

對回歸問題，最常用的 Loss 是均方誤差（Mean Squared Error, MSE）：

$$MSE = (1/n) \cdot \Sigma (y_i - \hat{y}_i)^2$$

其中 y_i 為真實值，$\hat{y}_i$ 為模型預測值，n 為樣本數。

為什麼要「平方」（補充說明）？至少有四個原因：

- **1. 不正負相消：**正誤差與負誤差會互相抵消；平方後只衡量距離，不計方向。
- **2. 放大顯著錯誤：**差距越大、懲罰越重，讓模型更想先把大錯修掉。
- **3. 數學上更易處理：**平方後函數處處可微，便於用梯度下降等方法求極小值。
- **4. 統計意涵：**背後假設誤差服從常態分佈，與最大似然估計的結果一致。

其他常見 Loss（補充說明）：

Loss	適用任務	特性
交叉熵（Cross-Entropy）	分類	把預測機率與真實標籤差距量化
平均絕對誤差（MAE）	回歸	對離群值較不敏感
Huber Loss	回歸	MSE 與 MAE 的折衷：小誤差

		用平方，大誤差用絕對值
Hinge Loss	分類（SVM）	鼓勵決策邊界兩側有足夠距離

6. 梯度下降：在濃霧裡下山

影片用「濃霧裡下山」做類比，非常直觀：

- **處境：**你站在山坡上，被濃霧包圍，看不見山谷位置。
- **方法：**用腳感覺哪邊下傾，選最斜的方向跨一步。
- **目標：**重複感覺、再跨步，直到腳底幾乎是平的為止。

把這個直覺對應到數學（補充說明）：

- **海拔 = Loss**Loss 函數是「海拔」——Loss 越低，海拔越低。
- **坡度 = 梯度** Loss 對參數的偏微分 ∇L 是「最陡的下坡方向」。
- **步伐 = 學習率 × 坡度**每一步更新參數：$w \leftarrow w - \eta \cdot \nabla L$，這就是「跨一步」。

整個迭代過程可以寫成虛擬碼：

```
for step in range(max_steps):
    preds = model(X, w)          # 用目前參數算預測
    loss  = loss_fn(preds, y)  # 計算 Loss
    grad  = dloss / dw          # 計算梯度（最陡下坡方向）
    w     = w - lr * grad       # 依學習率 lr 更新參數
```

> **影片原述｜Quote**　「梯度下降：濃霧裡下山，靠腳感知坡度。」

6.1 學習率（Learning Rate）：步伐太大太小都是災難

學習率 η 控制「每一步跨多大」。影片提醒：

- **η 太小：**Loss 下降非常緩慢，模型可能「走到天亮」都還沒到谷底，也容易卡在局部最低。
- **η 太大：**Loss 不降反升、甚至發散，模型永遠找不到谷底。

工程上（補充說明）有幾個常見策略幫助挑選合適的學習率：

- **學習率衰減（Learning Rate Decay）：**先設大再逐步縮小，例如 0.1 → 0.01 → 0.001。
- **自適應優化器：**Adam、RMSProp 等自適應方法會為不同參數個別調整 η。

- **小批次（Mini-batch）**：先用小批次（如 32、64 筆）算梯度再更新，兼顧速度與穩定。
- **學習率搜尋（LR Range Test）**：訓練前用一次小步驟掃描，找到 Loss 開始急降的 η 作為起點。

6.2 局部最小值：走進小窪坑怎麼辦？

影片提到「走進山谷的小窪坑怎麼辦」——這就是局部最小值（local minimum）問題。

對非凸的 Loss 曲面（尤其深層神經網路），存在很多窪坑。如果模型陷在某一個不太深的窪坑裡，就以為「已經到谷底」而停止進步。

- **方法一：動量**使用動量（momentum），把過去幾步的方向加權累積，幫助「翻過小丘」。
- **方法二：多次隨機初始化**隨機初始化多組參數各自訓練，最終挑選 Loss 最低者。
- **方法三：理解高維現象**神經網路的高維 Loss 曲面有研究指出，許多「局部最小」其實在表現上和全域最小相當。

7. Overfitting、Underfitting 與泛化

影片警告：「Loss = 0 為什麼很危險？」——這是 Overfitting 的招牌症狀。

模型在訓練資料 Loss 很低，甚至完美擬合，卻在沒看過的新資料表現很差：它把訓練資料的雜訊也「背下來」了。

現象	訓練 Loss	測試 Loss	原因
Underfitting（欠擬合）	高	高	模型太簡單，連訓練資料都學不好
Good fit（良好）	低	低	模型容量剛好，能抓到主要規律
Overfitting（過度擬合）	極低／0	高	模型太複雜，連訓練資料的雜訊都背下來

7.1 泛化（Generalization）：真正的目標

影片核心句：「真正的目標從來不是訓練資料完美，而是在『沒看過的資料』上也對。」這就是泛化能力。

判斷模型是否泛化的標準做法是「切資料」——下節詳述。

8. 為什麼要切三份：訓練、驗證、測試集

資料集	用途	允許被模型「看過」嗎？
訓練集（Training Set）	真正用來更新參數	可以（必須）
驗證集（Validation Set）	調超參數、選模型、早停（early stopping）	可以，但只用於決策，不直接訓練
測試集（Test Set）	最後一次評估泛化能力	不可以，只能在最終報告前使用一次

一般常見的切法（補充說明）約為 6 : 2 : 2 或 7 : 1.5 : 1.5。資料量極大時，測試集也可只佔 1%。

> **記憶口訣｜Tip**　訓練集學、驗證集挑、測試集只報一次——一旦把測試集的結果用於「再調整模型」，它就被『污染』了。

9. 資料洩漏（Data Leakage）：新手最常犯的致命錯誤

資料洩漏是指：在訓練階段讓模型看到本不該看到的資訊，使評估結果過度樂觀，但實際部署時崩盤。

常見類型（補充說明）：

- **1. 前處理洩漏：**把整批資料標準化（標準化時用到了測試集的均值與標準差）。
- **2. 時間洩漏：**時間序列資料隨機打散再切訓練／測試——模型「看到未來」。
- **3. 群組洩漏：**同一筆資料在訓練集與測試集重複出現。
- **4. 目標洩漏：**用「答案衍生的特徵」當輸入，例如用「已確診」推「是否確診」。
- **5. 特徵工程洩漏：**文字分類任務在切資料前先做了 TF-IDF。

預防原則（補充說明）：所有前處理、特徵工程、標準化都應該「在切完訓練／測試集之後」只用訓練集的統計量去 fit，然後才 transform 測試集。

10. 分佈偏移（Distribution Shift）：自駕車為什麼會在雪地傻掉？

即使資料切得很乾淨、模型在測試集表現很好，部署到真實世界仍可能全面失靈。原因之一是分佈偏移：訓練資料的分佈和實際遇到的分佈不一樣。

影片舉的自駕車例子非常直觀：

- **訓練環境：**若訓練資料大部分來自加州晴天路面，模型從未見過雪地與結冰標線。
- **部署環境：**到了下雪地區，模型對「車道線」「路面紋理」的判讀全錯，可能把雪地誤判為一般路面。

常見的分佈偏移類型（補充說明）：

類型	說明	例子
協變偏移（Covariate Shift）	輸入特徵的分佈改變	晴天 vs 雪天的相機影像
標籤偏移（Label Shift）	輸出類別的比例改變	疾病在健康族群與高風險族群的陽性率不同
概念偏移（Concept Drift）	輸入與輸出的對應關係隨時間改變	疫情期間「發燒」與「COVID-19」的關聯改變

工程上常見的對策（補充說明）：

- **持續學習：**持續蒐集並標記線上資料，定期再訓練。
- **主動學習：**主動挑選模型不確定的樣本請人標記。
- **領域適應：**在資料前處理或損失函數中估計並校正分佈差異（例如重要性加權）。

11. 本集核心觀念速記

影片在說明欄結尾整理了五句速記。把它們配上本章內容重新讀一次：

- **01.**機器學習 = 找函數 = 調旋鈕
- **02.**Loss 越低越好，但 Loss = 0 可能是 Overfitting
- **03.**梯度下降 = 濃霧下山，靠坡度走
- **04.**學習率太大會爆炸，太小走到天亮
- **05.**真正的目標：在「沒看過的資料」上也對

12. 33 集系列預告：五個季度

影片預告將推出一個 33 集的系列，一集一個機器學習演算法，從底層直覺講到原理、優缺點，再到手寫程式。整個系列分成五個季度：

季度	主題	內容簡介
第一季	經典監督式學習	由線性回歸起步，逐步推展到邏輯回歸、決策樹、支持向量機等經典模型。
第二季	非監督式學習	聚類、降維、關聯規則等「在沒有答案的資料中找結構」的方法。
第三季	機率與時序模型	以概率模型與時間序列為核心，例如 HMM、GMM、貝氏方法等。
第四季	神經網路與深度學習	從感知器到卷積、循環、Transformer，構成現代 AI 的骨幹。
第五季	強化學習	代理人、狀態、動作、獎勵：學會在環境中決策。

本集（EP 0）即是這 33 集開始前必備的「地圖」。

13. 章節對照：本手冊與影片重點

下表把本手冊的章節與影片說明欄的 18 個重點對照，方便複習時交叉查找。

本手冊章節	對應影片說明欄重點
1. 為什麼 AI 預測無處不在	（開場引子）你今天已經被機器學習服務幾百次了
2. 傳統寫程式 vs 機器學習	傳統寫程式 vs 機器學習：方向完全相反
3. 模型、參數、學習	模型 = 混音器，參數 = 旋鈕，學習 = 調旋鈕 / 最重要的一句話：所有機器學習都是在找一個函數

4. 三大門派	監督式學習／非監督式學習／強化學習
5. Loss 函數與 MSE	Loss 函數：怎麼衡量模型有多爛？/ 均方誤差（MSE）：為什麼要平方？
6. 梯度下降	梯度下降：濃霧裡下山，靠腳感知坡度 / 學習率（Learning Rate）/ 局部最小值
7. Overfitting 與泛化	Overfitting vs Underfitting：Loss = 0 為什麼很危險？/ 泛化（Generalization）
8. 訓練／驗證／測試集	訓練集、驗證集、測試集：為什麼要切三份？
9. 資料洩漏	資料洩漏（Data Leakage）：新手最常犯的致命錯誤
10. 分佈偏移	分佈偏移（Distribution Shift）：為什麼自駕車在雪地會傻掉
11. 速記	本集核心觀念速記（5 句）
12. 系列預告	33 集系列預告：五個季度，從線性回歸到強化學習

14. 自我檢核：你真的懂了嗎？

看完影片（或本手冊）後試著回答以下問題，看看自己有沒有抓到重點。

- **Q1.** 所有機器學習都可以被看成什麼過程？為什麼這種觀點有助於理解？
- **Q2.** MSE 為什麼「要平方」？舉出至少三個原因。
- **Q3.** 若學習率設太大，Loss 曲線通常會長什麼樣？
- **Q4.** Loss = 0 為什麼很危險？這代表模型一定過擬合嗎？
- **Q5.** 為什麼「切三份」而不是「切兩份」？
- **Q6.** 自駕車在雪地失靈，最可能對應哪一類分佈偏移？

參考答案｜Suggested answers A1. 找函數：從輸入對映到輸出，這個觀點把所有模型抽象成同一件事，有助於跨演算法比較。A2. 不正負相消、放大顯著錯誤、可微、與最大似然估計一致（任三）。A3. Loss 不降反升，或在低值附近震盪、甚至發散到 NaN。A4. 代表模型在訓練資料上完美擬合，可能把雜訊都背下來；在新資料上很可能表現很差。A5. 訓練集學參數、驗證集挑超參數與選模型、測試集只在最後評估一次。兩份切法

把「調參」與「最終評估」混在一起，會高估泛化能力。A6. 協變偏移：輸入影像的分佈（晴天 vs 雪天）改變。

15. 總結：這一集真正要帶走的東西

若要從本集濃縮出五個最重要的 takeaway：

- **1. 觀念翻轉：**機器學習的本質是「找函數」——決定輸入要對映到什麼輸出。
- **2. 模型 = 函數：**模型是用參數化的函數；訓練就是依資料調整參數。
- **3. Loss + 梯度：**Loss 把「對不對」量化；梯度下降用 Loss 的斜率沿著最陡下坡更新參數。
- **4. 泛化優先：**Loss 越低越好，但 Loss = 0 往往是 Overfitting；真正目標是「在沒看過的資料上也好」。
- **5. 部署紀律：**切三份資料、避免資料洩漏、並正視分佈偏移——是把模型從實驗室帶到現實的橋樑。

16. 資料來源｜Sources

來源類別	標題	作者／機構	形式	連結
【主要來源】	AI 預測的背後是什麼？｜監督式學習、梯度下降、Overfitting 一次搞懂『機器學習系列第 0 集』	Enzo 獨自升級	YouTube 說明欄（Description）	https://www.youtube.com/watch?v=LVlJ1j_hTlY
【補強 1】	機器學習是什麼？AI 機器學習定義、演算法類型、應用情境	亞利桑那州立大學	教學文章	https://cn.asu.edu/machine-learning/
【補強 2】	監督式學習 vs 非監督式學習差異在哪？機器學習兩大重點比較	PCschool	教學文章	https://www.pcschool.com.tw/blog/it/supervised-learning

【補強 3】	一文看懂监督学习（基本概念+4步流程+9 个典型算法）	easyAI	教學文章	https://easyai.tech/ai-definition/supervised-learning/
【補強 4】	The Elements of Statistical Learning	Hastie, Tibshirani, Friedman	經典教科書（監督式 / 非監督式學習章節）	https://hastie.su.domains/ElemStatLearn/
【補強 5】	Reinforcement Learning: An Introduction	Sutton & Barto	強化學習經典教科書	http://incompleteideas.net/book/the-book.html

編者聲明｜Editorial note　本手冊為非商業教育用途。影片中所有概念屬於影片作者 Enzo 與頻道「Enzo 獨自升級」原創；補充說明部分取自公開教學資源，並已於上表列示；本手冊不對原影片做任何逐字轉錄，如需最精確的用語，仍建議直接觀看原影片（YouTube ID：LVlJ1j_hTlY）。